



教育经历

上海交通大学	计算机科学与技术	硕士	2021.09 - 2024.03
<ul style="list-style-type: none">计算机科学与技术专业硕士在读，自然语言处理方向。导师：赵海荣誉/奖项：2021-2022学年鹰角奖学金			
上海交通大学	计算机科学与技术	本科	2017.09 - 2021.07
<ul style="list-style-type: none">GPA: 3.9/4.3; 排名: 20/150 (专业top 15%)荣誉/奖项：2018-2019学年喔塞科技·陈灏校友奖学金(top 10%)、2019-2020学年淮柴奖学金(top 5%)、连续三年校B等奖学金(top 10%)、2018年院级社会实践先进个人、2019年上海交通大学电院十佳志愿者、上海交通大学优秀毕业生			

科研和竞赛经历

多方对话理解预训练 (腾讯AI-Lab, ACL 2023)	第一作者	2022.08 - 2023.02
<ul style="list-style-type: none">我们总结了上一篇工作的缺点：1、生成式预训练在E-step计算隐变量后验概率时耗时过久；2、隐变量为单一轮次的收话人(addressee)，模型无法利用整个对话的回复结构信息(discourse structure)。基于上述问题，我们将观测变量的建模从回复生成转为上下文-回复匹配(Context-Response Matching)；并利用变分推断(VI)，将隐变量从单一轮次的addressee推广为整个对话的discourse structure。通过对VI优化目标ELBO中隐变量先验分布的推导，我们巧妙地将EM算法与VI结合，解决了EM算法开销过大和VI难以优化的问题。爬取收集了大量无标注的多方对话数据，利用上述算法进行多方对话理解模型的预训练。预训练模型在多个多方对话相关的下游任务上均取得最好的表现，大幅超越基线模型和以往工作。		
多方对话回复生成预训练 (ACL 2023)	第一作者	2022.04 - 2022.08
<ul style="list-style-type: none">我们发现多方对话文本中存在"收话人"(addressee)标注稀疏的问题，针对这一问题，我们将一句回复的addressee视为隐变量，利用建模了addressee的生成模型计算隐变量的后验概率，使用EM算法在无标注数据上迭代优化模型。我们的模型在多方对话回复生成数据集上超过了以往的工作，取得了SOTA结果。		
双向信息解耦的多轮对话建模 (EMNLP 2022)	第一作者	2021.05 - 2021.09
<ul style="list-style-type: none">对话文本具有天然的边界信息(utterance)以及时序特征，这对于对话理解十分关键，以往的研究却将其忽略。因此我们设计了双向信息解耦网络，在对话独有的utterance粒度上来显式建模对话文本的时序信息。我们设计了三种解耦层来从预训练语言模型的输出中解耦三种对应信息。在解耦出三种表征后，我们使用Mixtrue-of-Expert模块将其动态混合，并得到最后的表征用于下游任务。我们的模型对于回复选择、对话摘要和对话阅读理解任务均有提升，并取得了SOTA结果。在MuTual数据集的公开Leaderboard上，我们的模型从2021年8月到现在一直是第一名。论文链接：https://aclanthology.org/2022.emnlp-main.177/		
语义保留的代码理解对抗训练 (COLING 2022)	第一作者	2021.09 - 2022.03
<ul style="list-style-type: none">对抗训练在普通的自然语言文本理解任务上能够同时提高模型的泛化性和鲁棒性，但其对于源代码(Source Code)的功效还没有被研究。同时，以往在源代码上使用对抗训练的模型通常将内层的最大化任务定义为离散的语义保留的代码变换(semantic-preserving code transformations)，其为离散组合优化问题，难以优化并且与基于梯度的训练框架不兼容。我们把在连续嵌入空间(embedding space)上的对抗扰动与源代码文本的数据特性相结合，提出了语义保留的对抗性代码表征SPACE (Semantic-Preserving Adversarial Code Embeddings)，同时提高了针对源代码的预训练语言模型在各种下游任务上的鲁棒性和泛化性。论文链接：https://aclanthology.org/2022.coling-1.267/		
多方对话的机器阅读理解 (Findings of EMNLP 2021)	第一作者	2020.09 - 2021.05
<ul style="list-style-type: none">多方对话阅读理解中的两个问题：1、与双人对话相比，多方对话文本具有复杂的篇章结构和对话者信息流；2、基于长对话文本的问答中，对于问题能提供有用信息的文本较少。为解决两个问题，提出了两种自监督(和伪自监督)的辅助任务：关键词预测和对话者预测，来显式指导两种信息的建模，并将解耦出的两种信息进行融合以完成问答任务。在两个多人对话阅读理解数据集Molweni/FriendsQA上取得了当时的SOTA结果。论文链接：https://aclanthology.org/2021.findings-emnlp.176/		
科技战疫·大数据公益挑战赛第十名	核心成员	2020.03 - 2020.05
<ul style="list-style-type: none">参与“疫情期间网民情绪识别”赛题，在2048支参赛队伍中取得了第10名的成绩。主要负责模型架构和训练优化过程。		

实习工作经历

米哈游	鹿鸣实验室	2023.03 - 至今
● 负责虚拟人鹿鸣的对话系统开发和研究。		
腾讯AI-Lab	自然语言处理中心	2022.06 - 2023.02
● 针对多方对话理解展开研究，并撰写论文投稿ACL。		

技能/证书及其他

- 技能: Python , C++ , Photoshop , Premiere Pro , Pytorch
- 语言: 英语(托福: 100分, 六级: 615分, 四级: 687分), 日语(N2)
- 爱好: 摄影(曾获校青志队公益摄影大赛优秀作品奖), 视频制作(导演并拍摄过多部作品), 深度学习 , 自然语言处理